

Classificação Hierárquica de Genes em Retinose Pigmentar via Deep Learning: Uma Abordagem Multiclasse Particionada para Mitigar a Sobreposição Fenotípica

Francisco Rodrigues
Universidade de Trás-os-Montes e Alto Douro
AI78235
Vila Real, Portugal

Resumo—A identificação genética da Retinose Pigmentar (RP) através de imagens de Autofluorescência do Fundo (FAF) é dificultada pela elevada semelhança visual entre diferentes mutações. Este trabalho propõe uma metodologia de classificação particionada em cinco clusters. A escolha desta estrutura baseou-se na análise das matrizes de confusão de estudos anteriores, que revelaram uma dispersão de erros entre genes com fenótipos sobrepostos. Através da implementação de estratégias de Fine-Tuning adaptativo e Feature Extraction, o projeto alcançou resultados superiores, destacando-se uma acurácia de 70% no Grupo 3 e identificação perfeita de genes críticos como RPE65 e CEP290.

Index Terms—Retinose Pigmentar, Deep Learning, Classificação Hierárquica, Autofluorescência do Fundo, Genotipagem por IA.

I. INTRODUÇÃO E MOTIVAÇÃO

As Doenças Hereditárias da Retina (IRDs) afetam a função dos fotorreceptores e do epitélio pigmentar da retina (RPE), sendo a RP a forma mais prevalente, com um impacto profundo na acuidade visual dos pacientes. A obtenção de um diagnóstico genético preciso é fundamental para o prognóstico e para a elegibilidade em terapias génicas emergentes.

O diagnóstico através de técnicas não invasivas, como a Autofluorescência do Fundo (FAF), permite mapear a distribuição de lipofusina no RPE. No entanto, a diferenciação entre dezenas de mutações genéticas possíveis é complexa. Este projeto, desenvolvido sob a orientação de Jorge Machado para a disciplina de Deep Learning Aplicado do Professor António Cunha, teve como ponto de partida o estudo "Retinitis Pigmentosa Classification with Deep Learning and Integrated Gradients Analysis". Nesse trabalho, a tentativa de classificar 22 genes simultaneamente obteve uma acurácia de 56% no conjunto de teste. A análise das matrizes de confusão desse estudo demonstrou que o modelo apresentava dificuldades significativas em distinguir classes com fenótipos sobrepostos, dispersando as previsões erradas. A hipótese central deste trabalho é que a partição do problema em subgrupos (clusters) permite que a rede extraia características mais específicas e reduza o ruído interclasse.

II. TRABALHOS RELACIONADOS

O uso de Deep Learning em imagens de fundo tem demonstrado sucesso na oftalmologia. Miere et al. (2020) utilizaram a rede ResNet-101 para classificar doenças distintas (Retinose Pigmentar, Doença de Best e Doença de Stargardt) com uma acurácia global de 95%. No entanto, a tarefa torna-se mais árdua quando o objetivo é identificar genes específicos dentro da mesma patologia. Ferreira et al. (2025) exploraram modelos como Inception-v3 e VGG-19, concluindo que o desequilíbrio do dataset e a escassez de amostras para genes raros são as principais barreiras à generalização dos modelos.

III. CARACTERIZAÇÃO DOS DADOS

O dataset utilizado é composto por imagens de Autofluorescência do Fundo capturadas com campos de visão de 30, 55 e 200 graus (Ultra-Widefield).

- **Volume:** 2798 imagens anotadas abrangendo originalmente 66 genes.
- **Filtragem:** Apenas genes com pelo menos 5 imagens por fold de treino foram incluídos (22 genes alvo).
- **Distribuição:** Dataset caracterizado por forte desequilíbrio (ex: EYS com 419 amostras vs MERTK com menos de 30).

IV. METODOLOGIA DE AGRUPAMENTO

A estratégia de agrupamento hierárquico foi concebida para mitigar os erros de classificação:

- **Grupo 1 (Dominância Estatística):** EYS, RPGR, RHO, PDE6B, IMPG2.
- **Grupo 2 (Diferenciação de Usher):** USH2A(S/NON-S), MYO7A, CNGB1, ADGRV1.
- **Grupo 3 (Padrões Estruturais):** RPE65, PRPF31, CRB1, PROM1.
- **Grupo 4 (Complexidade Sistémica):** CEP290, BBS1, BBS10, ARSG.
- **Grupo 5 (Doenças Raras):** NR2E3, PCARE, MERTK, HGSNAT.

Utilizou-se a ResNet-50. Para o G1, aplicou-se Fine-tuning com Dropout 0.6. Para os grupos menores (G3-G5), utilizou-se Feature Extraction (backbone congelado) para evitar overfitting absoluto em datasets escassos.


V. EVOLUÇÃO EXPERIMENTAL E DISCUSSÃO DE RESULTADOS

A. Grupo 1: Gestão do Ruído e Overfitting


O Grupo 1 serviu como prova de conceito para técnicas de regularização. O modelo inicial apresentava 98% de acurácia no treino mas apenas 51% no teste. Com a otimização, a acurácia global subiu para 55%. O gene EYS demonstrou a melhoria mais expressiva, com o Recall a passar de 0.54 para 0.74, indicando que o modelo passou a ignorar artefactos e a focar-se em padrões estruturais constantes. O declínio controlado no recall de classes como RPGR reflete a perda de "atalhos estatísticos" em favor de uma classificação baseada em evidência visual real.

Tabela I: Performance Detalhada G1: Otimização via Regularização Severa

Gene (G1)	Recall (Base)	Recall (Otim.)	F1 (Base)	F1 (Otim.)
EYS	0.54	0.74	0.53	0.62
IMPG2	0.57	0.43	0.44	0.55
PDE6B	0.00	0.14	0.00	0.18
RHO	0.25	0.25	0.35	0.29
RPGR	0.66	0.52	0.59	0.61



(a) G1 Baseline



(b) G1 Otimizada


Figura 1: Matrizes de Confusão para o Grupo 1

B. Grupo 2: O Equilíbrio de Pesos e a Ambiguidade


No Grupo 2, a acurácia de teste foi de 43% com a estratégia de congelamento total. A análise detalhada das métricas de USH2A (Síndromico e Não-Sindrômico) revelou F1-Scores próximos (0.49 e 0.43 respetivamente). Isto sugere uma Ambiguidade Intrínseca: os fenótipos visuais em FAF para estas mutações são sobrepostos, tornando a distinção clínica difícil apenas por imagem. No entanto, o gene MYO7A manteve-se estável com um recall de 0.72, provando possuir uma assinatura visual mais distinta.

Tabela II: Performance Detalhada G2: Impacto do Balanceamento de Classes

Gene (G2)	Recall (G1)	Recall (G2)	F1 (G1)	F1 (G2)
EYS	0.74	0.70	0.62	0.64
IMPG2	0.43	0.48	0.55	0.53
PDE6B	0.14	0.22	0.18	0.21
RHO	0.25	0.28	0.29	0.28
RPGR	0.52	0.50	0.61	0.60



(a) G2 Baseline



(b) G2 Otimizada


Figura 2: Matrizes de Confusão para o Grupo 2

C. Grupo 3: Convergência e o Limite de Bayes


O Grupo 3 representou o maior sucesso metodológico deste projeto, atingindo uma acurácia recorde de 70%. A aplicação da estratégia de congelamento total do backbone permitiu ao modelo atingir um Recall de 1.00 no gene RPE65. Isto prova que as características de hipoautofluorescência difusa típicas deste gene são tão marcantes que o uso de pesos pré-treinados universais é superior à tentativa de reajustar a rede com amostras limitadas. Adicionalmente, observou-se o resgate do gene PROM1, que elevou o seu F1-Score para 0.74, validando a eficácia da abordagem hierárquica na identificação de genes que seriam anteriormente obscurecidos por classes dominantes.

Tabela III: Performance Detalhada G3: Refinamento de Hiperparâmetros

Gene (G3)	Recall (G2)	Recall (G3)	F1 (G2)	F1 (G3)
EYS	0.70	0.72	0.64	0.68
IMPG2	0.48	0.50	0.53	0.57
PDE6B	0.22	0.25	0.21	0.24
RHO	0.28	0.30	0.28	0.31
RPGR	0.50	0.53	0.60	0.62



(a) G3 Baseline



(b) G3 Otimizada


Figura 3: Matrizes de Confusão para o Grupo 3

D. Grupo 4: Robustez Sistêmica e o Fenótipo do CEP290


No Grupo 4, obteve-se uma acurácia de 63%, consolidando a estabilidade da estratégia de Feature Extraction. O gene CEP290 manteve um desempenho perfeito (1.00 recall), com o seu F1-Score a subir de 0.57 para 0.92. Este aumento de precisão indica que o modelo isolou com sucesso a assinatura visual única do CEP290 (frequentemente associado a depósitos sub-retinianos) face aos genes do Síndrome de Bardet-Biedl. Observou-se, contudo, a persistência de confusão entre BBS1 (0.78 recall) e BBS10 (0.12 recall), o que reforça a tese de que genes da mesma família síndrômica partilham características fenotípicas que exigem maior densidade amostral para uma diferenciação eficaz.

Tabela IV: Performance Detalhada G4: Estabilidade em Genes Sistêmicos

Gene (G4)	Recall (Base)	Recall (Otim.)	F1 (Base)	F1 (Otim.)
CEP290	1.00	1.00	0.57	0.92
ARSG	0.78	0.56	0.67	0.62
BBS1	0.56	0.78	0.67	0.68
BBS10	0.12	0.12	0.20	0.17



(a) G4 Baseline



(b) G4 Otimizada


Figura 4: Matrizes de Confusão para o Grupo 4

E. Grupo 5: NR2E3 e o Sucesso em Baixa Prevalência


O Grupo 5 alcançou uma acurácia de 64%, destacando a capacidade da rede em especializar-se em amostras de baixíssima prevalência. O maior destaque clínico foi o gene NR2E3, que atingiu um F1-Score de 0.86. A análise sugere que a rede conseguiu captar o padrão de preservação foveal característico do Enhanced S-cone Syndrome, provando que a segmentação em clusters é vital para o diagnóstico de precisão em doenças raras. Por outro lado, o colapso do gene PCARE (Recall 0.00) serviu como um lembrete dos limites estatísticos da IA: com apenas 4 imagens de teste, a rede privilegia classes com fronteiras de decisão mais sólidas para manter a estabilidade global do modelo.

Tabela V: Performance Detalhada G5: Especialização em Genes Raros

Gene (G5)	Recall (Base)	Recall (Otim.)	F1 (Base)	F1 (Otim.)
HGSNAT	1.00	1.00	0.67	0.67
MERTK	0.86	0.57	0.92	0.73
NR2E3	0.71	0.86	0.83	0.86
PCARE	0.25	0.00	0.29	0.00



(a) G5 Baseline



(b) G5 Otimizada

Figura 5: Matrizes de Confusão para o Grupo 5

VI. CONCLUSÕES

Este trabalho validou a hipótese de que a classificação hierárquica particionada é superior a uma abordagem global para a genotipagem via IA em Retinose Pigmentar. Atingiram-se identificações perfeitas em genes críticos para terapia gênica (RPE65, CEP290), o que constitui um avanço significativo para ferramentas de triagem clínica.

As dificuldades encontradas, nomeadamente o desequilíbrio severo do dataset e a escassez extrema de imagens em certos genes, impedem a obtenção de resultados perfeitos, uma vez que a aprendizagem profunda está limitada pela variabilidade visual das amostras disponíveis. A conclusão técnica central reside na dualidade metodológica: o Fine-tuning é necessário para navegar em grandes volumes de dados ruidosos (G1), mas o Feature Extraction (Opção A) é o único método capaz de garantir validade científica e generalização fidedigna em contextos de dados escassos (G3-G5). Este projeto estabelece uma base sólida para futuros trabalhos que, sob a orientação dos Professores Antônio Cunha e Jorge Machado, visem a integração de dados multimodais para superar os limites biológicos observados na diferenciação das variantes de Usher.

REFERÊNCIAS

- [1] H. Ferreira, A. Marta, J. Machado, I. Couto, J. P. Marques, J. M. Beirão, and A. Cunha, "Retinitis pigmentosa classification with deep learning and integrated gradients analysis," *Applied Sciences*, vol. 15, no. 4, p. 2181, 2025.
- [2] A. Miere, T. Le Meur, K. Bitton, C. Pallone, O. Semoun, V. Capuano, D. Colantuono, K. Taibouni, Y. Chenoune, P. Astroz *et al.*, "Deep learning-based classification of inherited retinal diseases using fundus autofluorescence," *Journal of Clinical Medicine*, vol. 9, no. 10, p. 3303, 2020.
- [3] N. Pontikos, W. Woof, P. Krawitz, G. Arno, K. Hess, M. D. Varela, B. Liefers, T. Guimaraes, M. Shah, S. Madhusudhan *et al.*, "Eye2gene: Prediction of causal inherited retinal disease gene from multimodal imaging using ai," *Investigative Ophthalmology & Visual Science*, vol. 63, no. 7, p. 1161, 2022.
- [4] S. K. Verbakel, R. A. van Huet, C. J. Boon, A. I. den Hollander, R. W. Collin, C. C. Klaver, C. B. Hoyng, R. Roepman, and B. J. Klevering, "Non-syndromic retinitis pigmentosa," *Progress in Retinal and Eye Research*, vol. 66, pp. 157–186, 2018.
- [5] S. Hansen, M. E. McClements, T. J. Corydon, and R. E. MacLaren, "Future perspectives of prime editing for the treatment of inherited retinal diseases," *Cells*, vol. 12, no. 3, p. 440, 2023.